

《机器学习及医学工程应用》自选题项目设计 (优化版)

研究主题设计

《医学图像分割的范式演进:从 **U-Net** 局部卷积、全局注意力到 **EMCAD** 轻量级混合架构》

逻辑主线 (**Storyline**):

医学图像分割的发展经历了三个重要阶段:

1. 纯 **CNN** 与编码-解码时代:以 **U-Net** 为代表,利用局部卷积和跳跃连接(Skip Connection)确立了医学分割的标准范式,但受限感受野,难以捕捉全局依赖。
2. 全局注意力时代:以 **Transformer** 为代表的自注意力机制被引入视觉领域(如论文中 EMCAD 使用的 PVTv2 编码器),解决了全局上下文提取的问题,但带来了巨大的计算代价。
3. 高效混合与多尺度注意力时代(本项目 **SOTA**):2024年的 **EMCAD** 提出,既然 Transformer 编码器已经提取了全局特征,解码器就不必再用沉重的标准卷积。它通过极轻量的多尺度深度可分离卷积(MSDC)和分组注意力门(LGAG),在极低的算力开销下达到了 SOTA。

本项目将沿着这条历史脉络,复现并对比这三种思想,深挖它们在不同条件下的性能边界与失效原因。

论文矩阵(严格符合要求)

1. 经典论文一:医学图像分割的绝对基石(引用量 > 15万)

- 论文名称: *U-Net: Convolutional Networks for Biomedical Image Segmentation*
- 作者与年份: Olaf Ronneberger 等, MICCAI 2015
- 项目角色: 作为最核心的 Baseline。EMCAD 论文中的 Table 1 和 Table 2 均将其作为首个对比基准。它代表了纯局部特征提取的巅峰。

2. 经典论文二:全局注意力的开端(引用量 > 15万)

- 论文名称: *Attention Is All You Need*
- 作者与年份: Ashish Vaswani 等, NeurIPS 2017
- 项目角色: 代表注意力机制的引入。虽然原论文是 NLP 领域的,但它是 EMCAD 骨干网络(PVTv2 Transformer)的理论源头。在项目中,可将其思想具象化为一个基于纯注意力机制的分割网络(如 Swin-Unet)作为对比。
- 对应的后续实际使用论文: *Swin-Unet: Unet-like Pure Transformer for Medical Image Segmentation*

3. 近年 **SOTA** 论文:轻量级多尺度注意力(代码开源, **CVPR 2024**)

- 论文名称: *EMCAD: Efficient Multi-scale Convolutional Attention Decoding for Medical*

Image Segmentation

- 发表级别: **CVPR 2024** (CCF A类)
- 硬核优势: 结合 PVTv2-B0 编码器, 参数量仅 **3.92M**, 计算量仅 **0.84G FLOPs** (见原论文 Table 1)。完全不用担心算力不足, 非常适合学生团队反复跑消融实验。

项目落地执行指南(紧扣 PPT 高分要求)

Phase 1: 复现与验证 (Reproducibility & Validation)

1. 数据集选择: 强烈建议选择原论文使用的 **Kvasir-SEG** (息肉分割) 或 **ISIC 2018** (皮肤病变)。

这两个是单目标二分类任务, 图片尺寸可 resize 到 256×256 , 训练极快。

2. 基准跑通:

- 跑通标准的 **U-Net** (CNN基准): 仅需几十分钟即可完成训练。
 - 推荐调用库: 强烈推荐直接使用 segmentation_models_pytorch (SMP) 库, 几行代码即可实例化一个极其标准的 U-Net。
 - **GitHub** 链接: https://github.com/qubvel/segmentation_models_pytorch
 - 调用示例: `smp.Unet(encoder_name="resnet34", encoder_weights="imagenet", in_channels=3, classes=1)`
- 跑通基于 **Transformer** 的基准模型 (注意力基准): 作为全局注意力时代的代表。
 - 推荐模型: **Swin-Unet** (纯 Transformer 的 U 型架构代表)。
 - **GitHub** 链接: <https://github.com/HuCaoFighting/Swin-Unet>
 - 配置建议: 使用官方默认的 Swin-T (Tiny) 配置, 参数量小, 对单卡非常友好。特别注意: 官方库要求下载 ImageNet 的预训练权重 (Pre-trained ckpt), 强烈建议你们跑两组对比 (从头训练 vs 加载预训练), 这刚好可以作为 Phase 2 失败分析的核心素材。
- 跑通本项目的 **SOTA** 模型 (轻量级多尺度注意力):
 - 使用官方开源代码跑通 PVT-EMCAD-B0。
 - **GitHub** 链接: <https://github.com/SLDGroup/EMCAD>
- 复现原论文 Table 1 中的部分指标 (如 Dice 相似系数), 以证明 Reproducibility。

Phase 2: 失败分析 (Failure Analysis - 拿满分的关键核心)

这是 PPT 中强调的重中之重。必须分析模型什么时候会失效 (Failure Case):

1. **U-Net** 为什么失效? (局部限制): 找出测试集中病灶非常大、或者形状极其不规则的图像。U-Net 容易产生分割断层, 因为它的卷积核感受野有限, 缺乏全局统筹 (Global Context)。
2. 基于 **Transformer** 的大模型为什么失效? (过拟合): 如果不使用官方提供的预训练权重 (Train from scratch), 直接在 Kvasir 这样只有 1000 张图的小数据集上从头训练 Swin-Unet, 由于 Transformer 缺乏 CNN 的归纳偏置 (Inductive Bias), 模型必然严重过拟合。你可以通过绘制极低的验证集 Dice 曲线来证明这一点。
3. **EMCAD** 的短板在哪里? (鲁棒性归因): EMCAD 追求极致的轻量化, 使用了极简的深度可分离卷积 (Depth-wise Conv)。
 - 假设与验证: 轻量级卷积对图像质量可能更敏感。在测试集图像上人为添加 高斯噪声 或 运动模糊 (模拟医疗仪器成像不佳)。

- 结果预测:EMCAD 的性能可能会出现急剧下降(Distribution Shift)。

Phase 3: 改进与方法创新 (Ablation & Improvement)

针对你们在 *Phase 2* 发现的 EMCAD 对噪声敏感或其它短板, 提出微小但合理的改进:

- 合理改进方案:在 EMCAD 论文中的 MSCB (Multi-scale Convolution Block) 模块前, 加入一个非常轻量的空间平滑化模块, 或者引入一层对抗训练(Adversarial Training)的数据增强策略。
- 消融实验 (**Ablation Study**):原论文的 Table 5 做了内核大小(Kernel Size [1, 3, 5])的消融。你们可以做鲁棒性消融:对比 标准EMCAD vs 加入平滑滤波的EMCAD 在“干净数据”和“含噪数据”下的 Dice 掉分斜率。只要掉分减缓了, 你们的方法创新就成立了。